GeekBrains

Основы Python

Урок 5. Генераторы и comprehensions. Множества

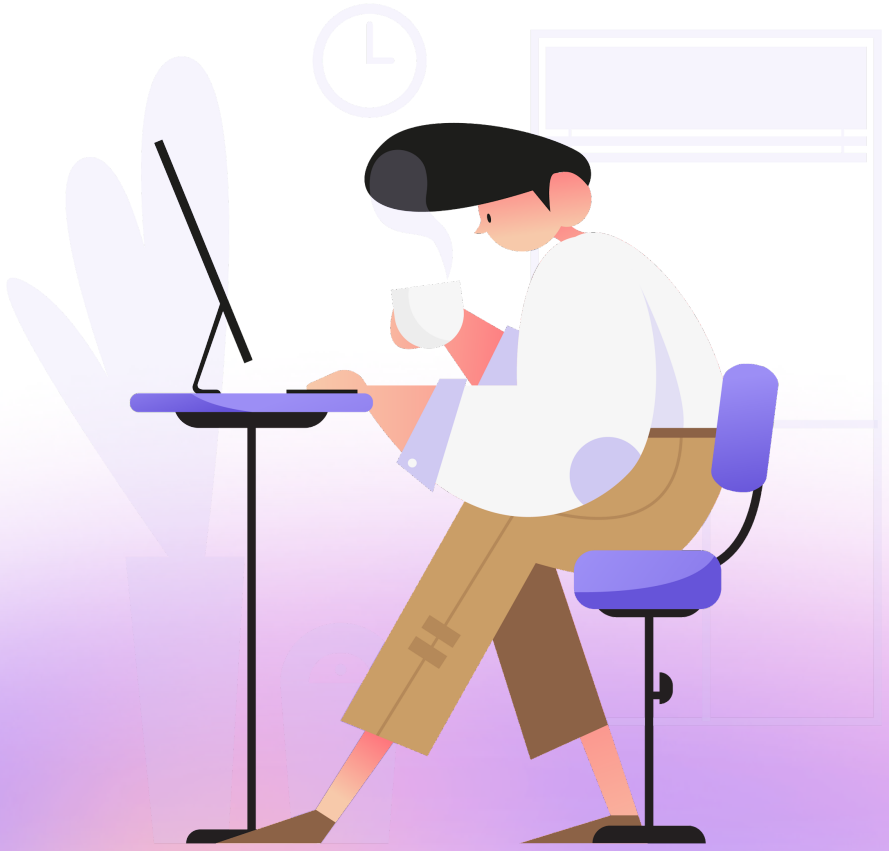

На этом уроке

1. Рассмотрим одну из важнейших тем — генераторы.
2. Узнаем о новом способе создания списков.
3. Вернёмся к хеш-таблицам — поговорим о множествах

Оглавление

Что такое генератор?

Представим, что нам в алгоритме необходима последовательность квадратов нечётных чисел до миллиона. Наивное решение будет выглядеть так:

```
import sys

nums = []
for num in range(1, 10 ** 6 + 1, 2):
   nums.append(num ** 2)
print(type(nums), sys.getsizeof(nums))  # <class 'list'> 4290008
```

Заполнили список в цикле. При помощи функции `getsizeof()` из модуля `sys` узнали, сколько байтов памяти занимает этот список. Если у вас 32-битная система, число будет в 2 раза меньше. Как можно раскритиковать такое решение? Мы храним ВСЕ числа в памяти. Вполне может быть, что этого не нужно делать, если в алгоритме необходимо итерироваться по ним — брать одно за другим. Именно для этих целей и придумали генераторы в `Python`:

```
...
nums_gen = (num ** 2 for num in range(1, 10 ** 6 + 1, 2))
print(type(nums_gen), sys.getsizeof(nums_gen))  # <class 'generator'> 112
```

Мы записали тот же цикл, но в одну строку и обернули в КРУГЛЫЕ скобки. Теперь вместо 4 Мбайт наш объект занимает в памяти 112 байт. Экономия серьёзная, но не в ущерб ли функциональности? Попробуем посчитать сумму:

```
...
from time import perf_counter

start = perf_counter()
nums_sum = sum(nums)
print(nums_sum, perf_counter() - start)
# 166666666666500000 0.022040908999999997

start = perf_counter()
nums_gen_sum = sum(nums_gen)
print(nums_gen_sum, perf_counter() - start)
# 166666666666500000 0.19718228200000004
```

Первый вывод — генератор работает в 10 раз медленнее. Причина есть: при суммировании элементов списка нужно только брать готовые значения по соответствующим адресам памяти и суммировать. Это работает быстро. В случае с генератором необходимо каждое значение сгенерировать (по факту вычислить) — это требует некоторого времени. Давайте теперь посмотрим глубже:

```
from time import perf_counter

start = perf_counter()
nums = []
for num in range(1, 10 ** 6 + 1, 2):
   nums.append(num ** 2)
nums_sum = sum(nums)
print(nums_sum, perf_counter() - start)
# 166666666666500000 0.24574289

start = perf_counter()
nums_gen = (num ** 2 for num in range(1, 10 ** 6 + 1, 2))
nums_gen_sum = sum(nums_gen)
print(nums_gen_sum, perf_counter() - start)
# 166666666666500000 0.19840974100000003
```

Получили совершенно другой результат. Догадались, почему? Теперь мы берём «честное» время — «под ключ». Ведь элементы списка тоже необходимо создать. В предыдущем примере они уже были готовы к моменту суммирования, в этом учитываем время, которое уходит на заполнение списка в цикле. И тут генератор вырывается вперёд. Это очень важный пример так называемых «ленивых вычислений». То есть генератор не вычисляет всю последовательность сразу. Он просто выдаёт нам очередной элемент и сохраняет своё состояние, как бы «спит»:

```
nums = []
for num in range(1, 10 ** 6 + 1, 2):
   nums.append(num ** 2)

nums_gen = (num ** 2 for num in range(1, 10 ** 6 + 1, 2))

print(nums[:3])
# [1, 9, 25]
print(next(nums_gen), next(nums_gen), next(nums_gen), sep=', ')
# 1, 9, 25
```

В отличие от списков, мы не можем обратиться к произвольному элементу генератора. Тут нет «параллельного» доступа — только последовательный. Вызываем функцию `next()`, получаем очередное значение. Это как «долистать» до страницы книги, а не открыть её сразу на нужной странице. Поэтому мы не можем делать обычные срезы для генераторов. Но можно использовать функцию `islice()` из модуля `itertools`:

```
...
from itertools import islice

print(*islice(nums_gen, 3))  # 49 81 121
```

Тут мы убедились, что генератор «помнит своё состояние»: уже 3 раза вызывали функцию `next()` до этого шага. Поэтому «срез» честно вернул 3 первых элемента из оставшейся последовательности. Причём `islice()` вернёт не список, а итератор (по сути тоже генератор). Мы из него вытянули все элементы при помощи `*`. У вас уйдёт немало времени на глубокое осознание нюансов, но пока можем думать, что итератор и генератор — по сути одно и то же.

Продолжим пример:

```
...
nums_gen_sum = sum(nums_gen)
print(nums_gen_sum)  # 16666666666499714

nums_gen_sum = sum(nums_gen)
print(nums_gen_sum)  # 0
```

Ещё одна особенность генераторов — они ОДНОРАЗОВЫЕ. То есть после вызова функции `sum()` мы получили сумму ОСТАВШИХСЯ элементов последовательности и всё. Больше генерировать нечего — поэтому при повторной попытке посчитать сумму получили ноль.

Вывод: если последовательность нужна в алгоритме более одного раза, использование генератора может быть неэффективным или приводить к ошибкам.

Генератор своими руками

Давайте ещё раз разберем синтаксис создания генератора:

```
nums_gen = (num ** 2 for num in range(1, 10 ** 6 + 1, 2))
```

Эта запись называется Generator Expression (генераторное выражение). В первой позиции мы описываем очередное возвращаемое генератором значение — в нашем случае квадрат числа. Дальше пишем цикл, в котором создаются исходные данные для этих значений. У нас это нечётные числа до миллиона включительно. А если нужен генератор английских букв? Попробуем:

```
eng_letters_gen = (chr(code) for code in range(ord('a'), ord('z') + 1))
print(*eng_letters_gen, sep='')  # abcdefghijklmnopqrstuvwxyz
```

Бывают более сложные алгоритмы генерации последовательностей. Например, генерация чисел Фибоначчи. Поэтому часто мы пишем **функции, возвращающие генераторы**:

```
import sys


def nums_generator(max_num):
    for num in range(1, max_num + 1, 2):
        yield num ** 2


nums_gen = nums_generator(10 ** 6)
print(type(nums_gen), sys.getsizeof(nums_gen))  # <class 'generator'> 112
print(sum(nums_gen))  # 166666666666500000
```

Первое — мы получили точно такой же генератор квадратов нечётных чисел, что и раньше. Второе — мы теперь можем многократно создавать такие генераторы для разных значений границы:

```
nums_1000_gen = nums_generator(10 ** 3)
print(sum(nums_1000_gen))  # 166666500
nums_100000_gen = nums_generator(10 ** 5)
print(sum(nums_100000_gen))  # 166666666650000
```

Рекомендуем поразмышлять над ключевым словом `yield`. Необходимо понять его роль и осмыслить разницу с `return`. Что делает это слово? Возвращает генератор. При этом все переменные в теле функции **сохраняют** свои значения до генерации следующего элемента — неважно, будет это в цикле `for in` или просто в результате вызова функции `next()`. Именно это хотят от вас услышать на собеседовании: генератор хранит своё состояние. А `return` возвращает результат вычислений, выполненных в функции. При этом значения всех переменных, которые были объявлены в теле функции, **исчезают**. При следующем вызове функции все будет с чистого листа.

Для закрепления функция-генератор букв:

```
def letters_generator(start, end):
    for code in range(ord(start), ord(end) + 1):
        yield chr(code)


eng_uppercase_letters = letters_generator('A', 'Z')
print(*eng_uppercase_letters, sep='')  # ABCDEFGHIJKLMNOPQRSTUVWXYZ
```

В каких случаях реализуем генераторы через функции? Когда генераторное выражение получается слишком сложным или вообще не позволяет реализовать требуемую логику.

Какие встроенные функции работают как генераторы (итераторы)? Вы их уже знаете: `range()`, `reversed()`, `map()`, `filter()`, `zip()`.

List Comprehensions: не генераторы!

Напишем генератор кубов чисел до 5 включительно:

```
nums_cube_gen = (num ** 3 for num in range(5 + 1))
print(type(nums_cube_gen), *nums_cube_gen)
# <class 'generator'> 0 1 8 27 64 125
```

А если нам в алгоритме нужен список? Можем выполнить преобразование:

```
nums_cube_gen = (num ** 3 for num in range(5 + 1))
nums_cube = list(nums_cube_gen)
print(type(nums_cube), *nums_cube)
# <class 'list'> 0 1 8 27 64 125
```

Но в Python есть «синтаксический сахар» для более лаконичной записи такого кода — List Comprehensions:

```
nums_cube = [num ** 3 for num in range(5 + 1)]
print(type(nums_cube), *nums_cube)
# <class 'list'> 0 1 8 27 64 125
```

В чём разница с генераторным выражением? Всего лишь скобки.

Важно: ЭТО НЕ ГЕНЕРАТОРЫ списков! Не надо их так называть. Кто-то неудачно перевел на русский язык, и многие повторяют, не понимая сути. Это не генератор, потому что здесь нет ЛЕНИВЫХ вычислений. В данном примере мы получаем обычный список альтернативным циклу-итератору способом. Давайте перепишем этот код по-старому:

```
nums_cube = []
for num in range(5 + 1):
    nums_cube.append(num ** 3)
```

`List Comprehensions`, как правило, работают быстрее, чем код, записанный через цикл `for in`. Они лаконичнее как минимум на одну строку. Но в результате мы всегда получаем список, а не генератор.

Внутри `List Comprehensions` можно использовать `List Comprehensions` — получаем Nested List Comprehensions. Например, нам необходимо сложить две матрицы. Можем решить задачу наивным способом:

```
matrix_1 = [
    [1, 4, 3, 3],
    [15, 0, 8, 11],
]
matrix_2 = [
    [17, 3, 2, 8],
    [4, 3, 6, 4],
]

matrix_sum = []
for i in range(len(matrix_1)):
    row = []
    for j in range(len(matrix_1[0])):
        row.append(matrix_1[i][j] + matrix_2[i][j])
    matrix_sum.append(row)
print(*matrix_sum, sep='\n')
# [18, 7, 5, 11]
# [19, 3, 14, 15]
```

Можем отрефакторить код при помощи `List Comprehensions`:

```
matrix_sum = [
    [matrix_1[i][j] + matrix_2[i][j] for j in range(len(matrix_1[0]))]
    for i in range(len(matrix_1))
]
```

Сложно читается? Это со временем пройдёт. Зато вместо шести строк кода получили одну. Да, это считается одной строкой, просто мы отформатировали в несколько для читабельности. А вы сможете переписать эти примеры через `zip()`? Если да — супер! Иначе повторяйте материал предыдущих уроков:

```
matrix_sum = [
    [cell_1 + cell_2 for cell_1, cell_2 in zip(row_1, row_2)]
    for row_1, row_2 in zip(matrix_1, matrix_2)
]
```

Это решение самое правильное с точки зрения языка `Python`. **Очень важно**, что тут **нет индексов**. Читабельность такого кода на порядок выше, чем предыдущих вариантов. В принципе любой математик его прочитает, даже если он не программист.

Решим задачу посложнее. Нам необходимо сделать данные плоскими (`flat`). Например, мы записывали данные о температуре воздуха в отдельную строку таблицы (списка) каждый день. Теперь нам нужен непрерывный ряд данных о температуре: не по дням, а в виде одномерного списка. Зачем? Например, чтобы построить график изменения температуры в течение недели (месяца, полугодия и т.д.) То есть от двумерных данных нужно перейти к одномерным (плоским). Решаем задачу через цикл:

```
weather_data = [
    [-17.5, -18.9, -21.0, -16.1],
    [-9.3, -11.7, -14.3, -15.8],
]

flat_weather_data = []
for row in weather_data:
    for el in row:
        flat_weather_data.append(el)
print(flat_weather_data)
# [-17.5, -18.9, -21.0, -16.1, -9.3, -11.7, -14.3, -15.8]
```

Мы могли бы решить задачу проще через метод `.extend()`, но иногда на собеседованиях «не разрешают» использовать таких помощников. Теперь решим задачу через `List Comprehensions`:

```
flat_weather_data = [el for row in weather_data for el in row]
```

Решение в одну строку. Надо только научиться «читать» такой код. Можно переформатировать:

```
flat_weather_data = [
    el
    for row in weather_data
        for el in row
]
```

А если нам нужно ещё отфильтровать данные? Например, берём только температуры до –20 градусов:

```
flat_weather_data_2 = [
   el for row in weather_data for el in row
   if el > -20
]
print(flat_weather_data_2)  # [-17.5, -18.9, -16.1, -9.3, -11.7, -14.3, -15.8]
```

Разумеется, можно записать это решение в одну строку.

НАСТОЯТЕЛЬНО рекомендуем как можно чаще заменять обычные циклы `List Comprehensions`. И не забывайте, что это не «генераторы»!

Развиваем успех: Dict Comprehensions

Есть ли в Python для словарей синтаксис, аналогичный `List Comprehensions`? Есть:

```
nums_cube = {num: num ** 3 for num in range(1, 5 + 1)}
print(nums_cube)  # {1: 1, 2: 8, 3: 27, 4: 64, 5: 125}
```

Разница лишь в наличии символа "`:`", разделяющего ключ и значение. Так выглядел бы обычный код для создания такого словаря:

```
nums_cube = {}
for num in range(1, 5 + 1):
   nums_cube[num] = num ** 3
```

`Dict Comprehensions` могут быть полезны для преобразования одного словаря в другой:

```
eng_ru = {'may': 'май', 'june': 'июнь', 'july': 'июль'}
ru_eng = {val: key for key, val in eng_ru.items()}
print(ru_eng)  # {'май': 'may', 'июнь': 'june', 'июль': 'july'}
```

В чём коварство такой манипуляции? Надо быть уверенным, что значения, как и ключи, уникальны. Иначе потеряете часть элементов исходного словаря:

```
eng_ru_nums = {'one': 'один', 'first': 'один', 'two': 'два'}
ru_eng_nums = {val: key for key, val in eng_ru_nums.items()}
print(ru_eng_nums)  # {'один': 'first', 'два': 'two'}
```

Множества в Python

Помните круги Эйлера из школьного курса математики? Что дают нам множества в разработке? Предположим, нам нужно взять из списка только уникальные значения. Можно решить эту задачу поверхностно:

```
basket = ['apple', 'samsung', 'apple', 'huawei', 'asus', 'samsung']
unique_brands = [el for el in basket if basket.count(el) == 1]
print(unique_brands)  # ['huawei', 'asus']
```

Многие скажут: «А что здесь такого? Код ведь работает!» Если вы напишете такое на собеседовании, провалите его. Предположим, что в списке `n=1000` элементов (на самом деле их может быть намного больше). Сколько раз выполняется цикл внутри `List Comprehension`? Да, `n` раз. Метод `.count()` обходит весь список и накапливает сумму вхождений объекта. То есть каждый раз он перебирает `n` элементов — это ещё `n` шагов на **каждой** итерации цикла. Итого получим $n * n = n^2 = 1\,000\,000$ шагов при выполнении этого кода. В реальной жизни это значит, что при росте нагрузки на ресурс **очень** быстро будет падать его производительность.

А что, если нам поискать такую структуру данных, в которой проверка наличия элемента не потребует полного перебора? К таким структурам относятся, например, хеш-таблицы. Более того, мы уже работали с хеш-таблицами: один из вариантов их реализации в `Python` — словари (`dict`). А другой — множества (`set`):

```
...
unique_brands = set()
tmp = set()
for el in basket:
   if el not in tmp:
```

```
        unique_brands.add(el)
    else:
        unique_brands.discard(el)
    tmp.add(el)
print(unique_brands)  # {'asus', 'huawei'}
```

Мы подразумеваем, что вы уже умеете работать с функцией `dir()` и посмотрели docstring у всех методов множеств. Если нет — дальше нельзя.

В примере мы итерируемся по элементам исходного списка и добавляем каждый элемент в множество `tmp` при помощи метода `.add()`. Подумайте, почему метод называется именно так, а не `.append()`, как у списков? Одно из **важнейших** особенностей множеств — отсутствие какого-либо порядка элементов внутри. Это значит, что мы можем проверить факт вхождения элемента в множество (оператор `in`), но у этого элемента нет никакого номера или индекса, как у тех же списков. При выводе множества через функцию `print()` вы можете каждый раз видеть разный порядок элементов — это нормально. В некоторых случаях, например если множество содержит одни числа, может наблюдаться один и тот же порядок элементов (по возрастанию), но это девиации от стандартного поведения.

Какой смысл у метода `.append()`? Добавить в конец списка. Есть ли у множества конец? Нет. И у метода `.append()` — тоже нет.

В начале каждой итерации цикла мы проверяем, встречался ли текущий элемент ранее. Эта манипуляция для множества условно стоит нам **один** шаг, а не **n** шагов, как было бы со списком. В этом и есть самая важная роль множеств в алгоритмах! Если текущий элемент не встречался ранее, добавляем его в результат, иначе — удаляем.

Важно: для удаления элемента из множества есть два метода:

- `.remove()` — если элемента нет, поднимет исключение KeyError;
- `.discard()` — если элемента нет, ничего не происходит.

Подумайте: можно ли в нашем примере использовать `.remove()`?

Итак, при размере входного списка 1000 элементов решили ту же задачу за 1000 шагов вместо 1 000 000. Но что ещё можно тут улучшить? Если потребуется вывод элементов в той же последовательности, как они встречаются в исходном списке, нужно будет написать ещё один цикл или `List Comprehension`:

```
...
unique_brands_ord = [el for el in basket if el in unique_brands]
print(unique_brands_ord)  # ['huawei', 'asus']
```

Как вы уже видели, множество можно создавать через имя класса. Есть альтернативный синтаксис:

```
pencil_colors = {'red', 'pink', 'green'}
```

Очень похоже на создание словарей. Разница — нет пар, только значения через запятую. Тот же список, но скобки другие.

Что будет, если несколько раз добавить элемент в множество? Ничего, если он же там уже есть. Это как включить уже включённый светильник. Иногда этим пользуются, чтобы убрать повторы объектов. Но есть опасность — вы **всегда** теряете исходный порядок элементов.

Множества позволяют отвечать на вопросы вида: «найдём всех пользователей, которые одновременно участвуют в этих двух чатах» или «найдём всех пользователей этого чата, которые не участвуют в другом чате», «найдём всех пользователей, которые участвуют в первом или втором чате».

```
chat_1 = {'user_1', 'user_5', 'user_7', 'user_8', 'user_11'}
chat_2 = {'user_1', 'user_2', 'user_2', 'user_7', 'user_9', 'user_10'}

chats_common = chat_1.intersection(chat_2)
print(chats_common)  # {'user_1', 'user_7'}

chat_1_only = chat_1 - chat_2
chat_2_only = chat_2 - chat_1
print(chat_1_only)  # {'user_11', 'user_5', 'user_8'}
print(chat_2_only)  # {'user_9', 'user_10', 'user_2'}

both_chats = chat_1.union(chat_2)
print(both_chats)
# {'user_11', 'user_7', 'user_2', 'user_5', 'user_10', 'user_9', 'user_1',
#  'user_8'}
```

Пересечение множеств находим через метод `.intersection()`. Обратите внимание, что вместо вызова метода можно использовать оператор `&`. Аналогично, разницу находим при помощи оператора `-` или метода `.difference()`. Для объединения мы вызвали метод `.union()`, но можно было использовать оператор `|`.

Снова множества — `frozenset`

Помните разницу между `list` и `tuple`? Изменяемость первых и неизменяемость вторых. Можно ли списки использовать в качестве ключей словаря? Нет. Можно ли списки добавлять в множества? Нет. А кортежи можно — они неизменяемы.

Можно ли множество использовать в качестве ключа словаря? Нет. Причина — множества изменяемы: мы можем добавлять или удалять из них элементы. А если в алгоритме нужно именно множество использовать в качестве ключа? Не преобразовывать же его в кортеж! Ведь тогда придётся ещё добавлять сортировку элементов, иначе из одного и то же множества получим разные кортежи. Вы же помните, что порядок элементов в множестве может быть любой? Значит, и в кортеже получится произвольный порядок, поэтому — только сортировать, но это будет костыль.

Вместо этого просто создаем `frozenset`. Название — говорящее.

```
chat_1 = frozenset(('user_1', 'user_5', 'user_7', 'user_8', 'user_11'))
chat_2 = frozenset(('user_1', 'user_2', 'user_2', 'user_7', 'user_9'))

chats_common = chat_1.intersection(chat_2)
print(chats_common)  # frozenset({'user_7', 'user_1'})
```

Получили неизменяемое множество. То есть можем делать всё то же самое, что и с обычными множествами, но не можем менять состояние. Вопрос: есть ли у `frozenset` метод `.add()`? Если вы ответили «да», тему изменяемости объектов надо повторить: не разобрались в ней до конца. Конечно, этого метода нет, как и методов `.discard)` и `.remove()`.

Set Comprehensions

Давайте рассмотрим ещё один способ сделать код лучше: set comprehensions.

```
import random

random_nums = {random.randint(1, 100) for _ in range(10)}
print(len(random_nums), random_nums)  # 9 {97, 45, 77, 78, 15, 19, 86, 91, 93}
```

Вы уже заметили, что у генераторных выражений и `comprehensions` очень похожий синтаксис. Однако не забывайте, что между ними принципиальная разница: генераторы хранят своё состояние и отдают значения по одному, например через функцию `next()`. В то время как `comprehensions` создают объекты соответствующих типов целиком. Разумеется, для них бесполезно вызвать функцию `next()`.

На сегодня всё.

Практическое задание

1. Написать генератор нечётных чисел от 1 до n (включительно), используя ключевое слово `yield`, например:

```
>>> odd_to_15 = odd_nums(15)
>>> next(odd_to_15)
1
>>> next(odd_to_15)
3
...
>>> next(odd_to_15)
15
>>> next(odd_to_15)
...StopIteration...
```

2. *(вместо 1) Решить задачу генерации нечётных чисел от 1 до n (включительно), не используя ключевое слово `yield`.

3. Есть два списка:

```
tutors = [
    'Иван', 'Анастасия', 'Петр', 'Сергей',
    'Дмитрий', 'Борис', 'Елена'
]
klasses = [
    '9А', '7В', '9Б', '9В', '8Б', '10А', '10Б', '9А'
]
```

Необходимо реализовать генератор, возвращающий кортежи вида `(<tutor>, <klass>)`, например:

```
('Иван', '9А')
('Анастасия', '7В')
...
```

Количество генерируемых кортежей не должно быть больше длины списка `tutors`. Если в списке `klasses` меньше элементов, чем в списке `tutors`, необходимо вывести последние кортежи в виде: `(<tutor>, None)`, например:

```
('Станислав', None)
```

Доказать, что вы создали именно генератор. Проверить его работу вплоть до истощения. Подумать, в каких ситуациях генератор даст эффект.

4. Представлен список чисел. Необходимо вывести те его элементы, значения которых больше предыдущего, например:

```
src = [300, 2, 12, 44, 1, 1, 4, 10, 7, 1, 78, 123, 55]
result = [12, 44, 4, 10, 78, 123]
```

Подсказка: использовать возможности `python`, изученные на уроке. Подумайте, как можно сделать оптимизацию кода по памяти, по скорости.

5. Представлен список чисел. Определить элементы списка, не имеющие повторений. Сформировать из этих элементов список с сохранением порядка их следования в исходном списке, например:

```
src = [2, 2, 2, 7, 23, 1, 44, 44, 3, 2, 10, 7, 4, 11]
result = [23, 1, 3, 10, 4, 11]
```

Подсказка: напишите сначала решение «в лоб». Потом подумайте об оптимизации.

Задачи со * предназначены для продвинутых учеников, которым мало сделать обычное задание.

Дополнительные материалы

1. Лутц Марк. Изучаем Python.
2. Модуль datetime.

Используемая литература

Для подготовки данного методического пособия были использованы следующие ресурсы:

1. https://realpython.com/python-sets/.
2. https://wiki.python.org/moin/TimeComplexity.
3. https://docs.python.org/3/.